Bitácora final de desarrollo asistido

Jorge Josué Flores González · MAI 540 · 7 de noviembre de 2026

Alcance y fuentes del registro

Esta bitácora consolida las bitácoras conservadas de los módulos 3 a 7, los registros del repositorio y las ejecuciones del capstone. La secuencia por módulo no implica que todas las actividades se realizaran durante la semana calendario prevista. No se dispone aquí de evidencia suficiente para reconstruir sesiones específicas de los módulos 1 y 2; no se les atribuyen prompts, pruebas ni resultados.

Módulos 1 y 2: límite documental

La reflexión inicial se apoya en las consultas posteriores del autor, quien solicitaba orientación para ejecutar celdas, entender resultados y publicar archivos. No se presenta ese contexto como evidencia de actividades técnicas no conservadas de las primeras dos semanas.

Módulo 3: ejecución y comparación

La bitácora de la Tarea 3.2 registra el uso de Codex para completar funciones, mantener particiones comunes y comparar modelos mediante validación cruzada. Las consultas sobre biopsias también llevaron a distinguir el resultado con fuga del obtenido al excluir sesiones de tratamiento. Se aprendió a verificar qué información entra al modelo, en vez de aceptar un accuracy perfecto sin revisar su origen.

Módulo 4: auditoría reutilizable

Las bitácoras documentan criterios para métricas, partición, selección de parámetros y subgrupos. La Skill se refinó para incluir selección dentro del entrenamiento y métricas de regresión. Posteriormente Claude Code realizó revisiones estáticas; estas no se confunden con ejecución numérica. En Insurance se conservó una copia con fuga deliberada y se distinguió mejora de validez de mejora aparente del ajuste.

Módulo 5: definición del capstone y confidencialidad

El autor eligió QA farmacéutica, descartó un proyecto relacionado con Sanando desde la Raíz y exigió proteger la confidencialidad. Se aprobó el uso de datos sintéticos representativos y la declaración sobre NDA. Codex implementó generación reproducible, K-Means, PCA y herramientas MCP. La bitácora registra nueve llamadas de cliente y siete pruebas, sin atribuir resultados regulatorios a la demostración.

Módulo 6: evaluación honesta

La bitácora de la Tarea 6.2 registra validación anidada, comparación de modelos y un intercambio entre detección de créditos malos y exactitud. La selección mantuvo el criterio declarado aun cuando otra métrica empeoró. Este aprendizaje se trasladó al capstone al reservar datos, elegir k dentro de entrenamiento y conservar resultados de sensibilidad desfavorables.

Módulo 7: automatización y límites del verificador

La bitácora de la Tarea 7.2 conserva veinte generaciones locales y la aplicación de dos versiones del verificador a los mismos textos. Los rechazos pasaron de siete a catorce, pero quedaron cinco textos problemáticos aceptados según revisión asistida. La conclusión fue reconocer el alcance limitado de reglas textuales, no afirmar que aprobar pruebas garantiza veracidad semántica.

Dirección humana y asistencia

Las decisiones humanas documentadas fueron la elección del sector, la restricción NDA, la exigencia de ahorrar recursos y la corrección de notas personales en entregables. Codex propuso e implementó detalles de modelado y documentación. No se atribuyen al autor ediciones manuales del código que no constan en los registros.

Módulo 8: construcción, auditoría y cierre

La solicitud fue continuar el capstone y cumplir las entregas. Se leyó la guía y se reutilizó el proyecto de QA en lugar del ejemplo de crédito. Codex implementó selección de k anidada, línea base, prueba reservada y análisis OOF. Se documentaron ramas y un pull request con revisión estructurada, respuestas y fusión; la revisión asistida no se presentó como una revisión de un compañero.

La auditoría detectó perfiles que mezclaban filas reservadas, una advertencia no visible en la app y falta de análisis de sensibilidad. Se restringieron los perfiles a desarrollo, se agregó la advertencia y se midió el ARI al retirar retraso CAPA. El ARI de 0,2544 se mantuvo como límite. Las diecinueve pruebas de la Parte 1 aprobaron y se reprodujo la instalación desde una copia limpia.

Para la Parte 2 se agregó análisis por áreas, antigüedad y recurrencias sobre predicciones OOF. La prueba de estrés mantuvo modelo y escala congelados; aumentó 30 días dos variables y cambió 25 de 60 asignaciones. Se añadieron pruebas de cortes, conteos y no modificación de entradas. La suite final aprobó 21 pruebas y 8 subpruebas. Un intento inicial de escribir las pruebas usó una ruta duplicada y falló; se corrigió la ruta antes de ejecutar la suite final. No se trató ese fallo de escritura como una prueba aprobada.

Se prepararon el informe, la presentación y un guion de tres minutos. Los resultados se sustentan en validacion.json, predicciones_oof.csv, entrega82/analisis.json y los registros pytest. La ejecución por otra persona, la grabación y la presentación oral permanecen sin evidencia y no se declaran realizadas. La solicitud de incompleto no se interpreta como exención automática de esos requisitos.

Reflexión sobre la evolución del criterio técnico

Al inicio de los intercambios conservados, mi atención estaba en ejecutar el cuaderno y obtener una entrega que funcionara. Preguntaba si debía ejecutar una celda o si una pantalla mostraba el resultado correcto. A lo largo del curso, mi criterio pasó a exigir evidencia de cómo se obtuvo ese resultado: qué datos se usaron, qué parte quedó reservada y qué limitaciones permanecían.

Un ejemplo concreto es la evaluación del capstone. Una segmentación estable entre semillas parecía suficiente para respaldar los grupos. Sin embargo, al retirar una variable, el ARI descendió a 0,2544. Hoy no describiría esa herramienta simplemente como robusta: distinguiría estabilidad de inicialización, sensibilidad a variables y utilidad profesional. Mantener el resultado desfavorable aporta más que buscar una cifra que confirme la propuesta.

También aprendí a dirigir al asistente con restricciones verificables: conservar el trabajo anterior, no modificar resultados para ocultar alertas y documentar la procedencia sintética de los datos. La asistencia aceleró implementación y redacción, pero no reemplaza mi responsabilidad de revisar el alcance ni la aceptación por usuarios. Mi decisión final es presentar un prototipo exploratorio reproducible y reconocer qué falta antes de usarlo en un proceso farmacéutico real.